




기술 구조도

AI 기반 YouTube 콘텐츠 큐레이션 기술 아키텍처 (비용 최소화)







사용 기술 요약

모듈	사용 기술	역할
Chrome Extension	Manifest V3, JavaScript	YouTube DOM 제어 및 UI
Content Collector	DOM Parser, MutationObserver	추천 영상 메타데이터 수집
Preprocessing	fastText, KeyBERT	언어 감지 및 키워드 추출
Embedding AI	all-MiniLM-L6-v2	영상 의미를 벡터로 변환
Similarity	Cosine Similarity	사용자 선호와 콘텐츠 유사도 계산
Planner	Qwen3-4B-Instruct 또는 Gemma 3 4B	자연어를 선호 프로필(JSON)로 변환
Sourcer	YouTube Data API v3	새로운 후보 영상 검색
Ranker	Weighted Borda Count	관련성·최신성·인기도 통합 순위
Diversification	MMR	중복 추천 제거 및 다양성 확보
Backend	FastAPI	추천 파이프라인 및 API
Database	SQLite / PostgreSQL	사용자 프로필 및 피드백 저장

이 구성이 좋은 이유

- **비용 최소화:** OpenAI API 없이 로컬 LLM(Qwen3-4B 또는 Gemma 3 4B)을 사용하고, 임베딩 모델인 **all-MiniLM-L6-v2**도 무료이므로 운영 비용이 거의 들지 않습니다.
- **역할 분리:** LLM은 **Planner**에서만 사용해 자연어를 선호 프로필로 변환하고, **Curator**는 MiniLM 임베딩과 Cosine Similarity만으로 빠르게 관련성을 계산합니다.
- **재현성 확보:** 최종 추천은 AI가 아니라 **Weighted Borda + MMR**로 결정해 결과를 설명하고 재현하기 쉽습니다.
- **확장성:** 나중에 성능을 높이고 싶다면 Curator에 LLM 재평가 단계를 추가하거나 Planner의 로컬 LLM을 더 큰 모델로 교체하는 것만으로 확장이 가능합니다.

YouTube Content Curation System - End-to-End Architecture

